

Control de Congestión

Ing. Gustavo Villarreal


Congestión

- Cuando hay demasiados paquetes presentes en una red (o en una parte de ella), hay retardo o pérdida en los paquetes y se degrada el desempeño. Esta situación se llama **congestión**.
- Las capas de red y de transporte comparten la responsabilidad de manejar la congestión.
- Como ésta ocurre dentro de la red, la capa de red es quien la experimenta en forma directa y en última instancia debe determinar qué hacer con los paquetes sobrantes.
- Sin embargo, la manera más efectiva de controlar la congestión es reducir la carga que la capa de transporte coloca en la red. Para ello se requiere que las capas de red y de transporte trabajen en conjunto.
- En esta unidad analizaremos los aspectos de la congestión relacionados con la red.
- A menos que la red esté bien diseñada, puede experimentar un **colapso por congestión**, en donde el desempeño se desploma a medida que aumenta la carga ofrecida más allá de la capacidad.
- Esto puede ocurrir debido a que los paquetes se pueden retrasar el tiempo suficiente dentro de la red como para que ya no sean útiles cuando salgan de ella.

Control de congestión

- Los tiempos de servicio aumentan de forma dramática cuando una línea o un router se aproxima a la saturación.
- No es posible ocupar una línea al 100% (tiempo de servicio infinito).
- Los buffers grandes permiten no descartar paquetes, pero aumentan el retardo. Esto puede causar retransmisiones y generar aún más tráfico.
- Cuando hay congestión severa el rendimiento global disminuye.

Efectos de la congestión en el rendimiento y el tiempo de servicio




Control de flujo vs. Congestión

- Vale la pena recalcar la diferencia entre el control de la congestión y el **control de flujo**, pues la relación es muy sutil.
- El **control de congestión** se ocupa de asegurar que la red sea capaz de transportar el tráfico ofrecido. Es un asunto global, en el que interviene el comportamiento de todos los hosts y enrutadores.
- En contraste, **el control de flujo** se relaciona con el tráfico entre un emisor particular y un receptor particular. Su tarea es asegurar que un emisor rápido no pueda transmitir datos de manera continua a una velocidad mayor que la que puede absorber los paquetes el receptor.

Métodos para evitar la congestión

- La presencia de congestión significa que la carga es (temporalmente) mayor de la que los recursos (en una parte de la red) pueden manejar.
- Dos soluciones podrían ser aplicadas: aumentar los recursos o reducir la carga.
- Estas soluciones por lo general se aplican en distintas escalas de tiempo, para prevenir la congestión o reaccionar ante ella una vez que se presenta.



Escalas de tiempo de los métodos para el control de la congestión.

Aumento de recursos

- La manera más básica de evitar la congestión es construir una red que coincida bien con el tráfico que transmita. Si hay un enlace con poco ancho de banda en la ruta a través de la cual se dirige la mayor parte del tráfico, es probable que haya congestión.
- Algunas veces se pueden agregar recursos en forma dinámica cuando hay un problema grave de congestión; lo más frecuente es que los enlaces y enrutadores que se utilizan mucho en forma regular se actualicen a la primera oportunidad. A esto se le conoce como **aprovisionamiento** y ocurre en una escala de tiempo de meses, con base en las tendencias de tráfico de largo plazo.
- Para aprovechar al máximo la capacidad existente de la red, las rutas se pueden ajustar a los patrones de tráfico que cambian durante el día, a medida que los usuarios de la red entran y salen en distintas zonas horarias. Por ejemplo, se pueden cambiar las rutas para desviar el tráfico de las mismas que se utilizan mucho si se cambian las ponderaciones de las rutas más cortas. A esto se le conoce como **enrutamiento consciente del tráfico** (*traffic-aware routing*).
- También es útil dividir el tráfico entre varias rutas, sin embargo, en ocasiones no es posible aumentar la capacidad. La única forma entonces para combatir la congestión es reducir la carga.


Reducción de carga

- En una red de circuitos virtuales, se podrían rechazar las nuevas conexiones si provocaran el congestionamiento de la red. A esto se le conoce como **control de admisión**.
- Cuando la congestión es inminente la red puede distribuir retroalimentación al origen cuyos flujos de tráfico sean responsables del problema; es decir, la red puede solicitar al origen que regulen su tráfico, o puede reducir el tráfico por sí misma.
- Esto trae dos problemas: cómo identificar el comienzo de la congestión y cómo informar al origen que necesita reducir su velocidad.
- Para el primer caso, los routers pueden monitorear la carga promedio, el retardo de encolamiento o la pérdida de paquetes y a medida que los valores aumentan significa que aumenta la congestión.
- Para el segundo caso, los routers deben participar en un lazo de retroalimentación con los orígenes, lo que implica una perfecta sincronización entre el momento que se detecta la congestión y el aviso al origen para disminuya el tráfico.
- Encontrar una retroalimentación oportuna no es un sencillo, entonces se pueden tener routers adicionales que envíen más mensajes cuando la red ya se encuentra congestionada.
- Por último, cuando todo lo demás falla, la red se ve obligada a descartar los paquetes que no puede entregar. Esto es **desprendimiento de carga** (*load shedding*).

Como evitar ‘de entrada’ la congestión

- *Cobrar* a los usuarios por el tráfico. Ej.: X.25
- Habilitar *recursos adicionales*. Ej.: RDSI
- Utilizar *rutas alternativas*. Ej.: routing dinámico.
- Imponer *límites* a los usuarios. Ej.: Frame Relay (CIR). Requiere labor de policía.
- ‘*Suavizar*’ las ráfagas. Ej. : ATM (pozal agujereado)
- *Planificar* caudales utilizados y reservar (QoS). Ej.: videoconferencia, aplicaciones multimedia.
- En redes orientadas a conexión aplicar *control de admisión*. Ej.: ATM, red telefónica.

Control de Admisión



Si se supera el Control de Admisión la red y el usuario pactan un contrato de tráfico

Como detectar la congestión


- A nivel de red:
 - ✓ Porcentaje de paquetes descartados
 - ✓ Longitud media de las colas en las interfaces de los routers
- A nivel de transporte:
 - ✓ Retardo medio de los paquetes
 - ✓ Desviación media del retardo (jitter)
 - ✓ Porcentaje de paquetes perdidos (suponiendo que no se debe a errores)

Notificar una situación de congestión


- Notificación implícita (descarte de paquetes):
 - ✓ El emisor bajará el ritmo (supondrá que se han perdido por congestión). Ej. TCP/IP.
- Notificación explícita (avisos al emisor):
 - ✓ Paquetes informativos o de alerta enviados al emisor por los routers. Ej. ATM, Frame Relay.
 - ✓ Aviso ‘piggybacked’ en un paquete de datos dirigido al emisor. (ATM, Frame Relay).
 - ✓ Aviso ‘piggybacked’ en un paquete de datos dirigido al receptor para que avise al emisor. (Frame Relay).
 - ✓ Aviso salto por salto.

Mecanismos de control de congestión

Implícitos:




Explícitos:



Medidas ante una situación de congestión

- Reducir o congelar el envío de paquetes de los hosts hasta que no haya congestión.
- En algún caso los routers intermedios pueden ayudar reteniendo parte de los paquetes en sus buffers.
- Descartar paquetes. A veces estos llevan alguna indicación de su importancia para el descarte (paquetes de 1ª y 2ª clase).
- Descarte inteligente, ej.: si se descarta un fragmento descartar también los demás.

Paquetes de alerta o regulador



Con efecto en el emisor

Con efecto en los
nodos intermedios

Problemas del control de congestión

- Se pueden dar situaciones cíclicas que impidan un aprovechamiento eficiente de los recursos (todos los hosts bajan el ritmo a la vez).
- Algunos creen que la lucha contra la congestión por mecanismos sofisticados (explícitos) es una batalla perdida (los remedios llegarán demasiado tarde para ser útiles).
- El uso de notificación explícita puede agravar aún más el problema.

Algoritmos de control de congestión

- Existen 2 (dos) criterios o visiones, bien definidos a la hora de aplicar algoritmos de control de congestión:
- Aquellos que sostienen que el control de congestión se debe calcular y determinar desde el diseño la red (algoritmos de ciclo cerrado o algoritmos pasivos).
- Aquellos que sostienen que las redes deben diseñarse con una capacidad teórica y luego deben adecuarse a las variaciones de caudal del tráfico que las atraviesa (algoritmos de ciclo abierto o algoritmos reactivos).

Algoritmos de control de congestión

- Algoritmos de control abierto
 - Implementan un buen diseño de la red → evitar la congestión
 - Deciden cuándo aceptar tráfico nuevo
 - Deciden cuándo y cuáles paquetes descartar
 - Las decisiones relacionadas con la congestión se toman independientemente del estado de la red
- Algoritmos de control cerrado
 - Monitorean el sistema para detectar cuándo y dónde se producen congestiones (% de paquetes descartados, retardos de paquetes, etc.)
 - Informan sobre la congestión a quienes puedan solucionar el problema
 - Toman medidas correctivas

Calidad de Servicio (QoS)

- Las técnicas que se analizaron fueron diseñadas para reducir la congestión y mejorar el rendimiento de la red.
- Pero existen aplicaciones (y clientes) que exigen a la red garantías más sólidas de desempeño que “lo mejor que se pueda hacer en base a las circunstancias”.
- En especial, las aplicaciones multimedia necesitan con frecuencia una tasa de transferencia real mínima y una latencia máxima para trabajar.
- Una solución sencilla para proporcionar una buena calidad del servicio es construir una red con la suficiente capacidad para cualquier tráfico que maneje. El nombre de esta solución es **exceso de aprovisionamiento** (*overprovisioning*). Pero es muy costoso.
- Los mecanismos de calidad del servicio permiten que una red con menos capacidad cumpla con los requerimientos de la aplicación con la misma eficiencia, a un menor costo.
- Es necesario considerar cuatro aspectos para asegurar la calidad del servicio:
 - ✓ Lo que las aplicaciones necesitan de la red.
 - ✓ Cómo regular el tráfico que entra a la red.
 - ✓ Cómo reservar recursos en los enrutadores para garantizar el desempeño.
 - ✓ Si la red puede aceptar o no más tráfico en forma segura.

Características del tráfico

- Tendencias en el tráfico de red
 - ✓ Los tipos de demandas de voz, video y tráfico de datos en la red son muy diferentes.
- Voz
 - ✓ La voz es muy sensible a las demoras y los paquetes descartados; no existe una razón para retransmitir la voz si los paquetes se pierden.
 - ✓ Los paquetes de voz deben recibir una prioridad mayor a la de otros tipos de paquetes.
 - ✓ La voz puede tolerar una cierta cantidad de latencia, fluctuación y pérdida sin efectos aparentes.

Voz

- Fluida
- Favorable
- Sensible a las caídas
- Sensible al retraso
- Prioridad UDP



Características del tráfico (Cont.)

- Video

- ✓ En comparación con la transmisión de voz, el video es menos resistente a pérdidas y tiene un mayor volumen de datos por paquete.
- ✓ El video puede tolerar cierta cantidad de latencia, fluctuación y pérdida sin ningún efecto notable.

- Datos

- ✓ Aplicaciones de datos que no tienen tolerancia a la pérdida de datos, como el correo electrónico y las páginas web, el uso de TCP para asegurarse de que, si los paquetes se pierden en tránsito, se envíen nuevamente.
- ✓ El tráfico de datos es relativamente insensible a las caídas y demoras en comparación con la voz y el video.

Video

- Con ráfagas
- Voraz
- Sensible a las caídas
- Sensible al retraso
- Prioridad UDP



Datos

- Fluido o con ráfagas
- Benigno/voraz
- Insensible a las caídas
- Insensible al retraso
- Retransmisiones de TCP



Requerimientos de Calidad de Servicio de las aplicaciones

Aplicación	Fiabilidad	Retardo	Jitter	Ancho de Banda
Correo electrónico	Alta (*)	Alto	Alto	Bajo
Transferencia de ficheros	Alta (*)	Alto	Alto	Medio
Acceso Web	Alta (*)	Medio	Alto	Medio
Login remoto	Alta (*)	Medio	Medio	Bajo
Audio bajo demanda	Media	Alto	Medio	Medio
Vídeo bajo demanda	Media	Alto	Medio	Alto
Telefonía	Media	Bajo	Bajo	Bajo
Vídeoconferencia	Media	Bajo	Bajo	Alto

(*) La fiabilidad alta en estas aplicaciones se consigue automáticamente usando el protocolo de transporte TCP.

QoS se refiere a la habilidad de la red para ofrecer prioridad a unos determinados tipos de tráfico, sobre diferentes tecnologías.

¿Cuándo una red provee QoS?

- Antes de que la red pueda hacer garantías de QoS, debe saber qué tráfico está garantizando.
- El **modelado de tráfico** (*traffic shaping*) es una técnica para regular la tasa promedio y las ráfagas de un flujo de datos que entra a la red.
- Al QoS lo definen 4 parámetros:
 - ✓ QoS está directamente relacionado con el tamaño de colas y la congestión de la red, con la velocidad de conmutación y el ancho de banda de los enlaces.
- QoS provee de mejores y más predecibles servicios a la red mediante:
 - ✓ Soporte de ancho de banda dedicado.
 - ✓ Mejorando la características de pérdida de paquetes.
 - ✓ Evitando y manejando la congestión de la red.
 - ✓ Organizando el tráfico.
 - ✓ Introduciendo prioridades de tráfico a lo largo de la red.
- Decimos que una red o un proveedor ofrece ‘Calidad de Servicio’ o QoS (Quality of Service) cuando se garantiza el valor de uno o varios de los parámetros que definen la calidad de servicio que ofrece la red. Si el proveedor no se compromete en ningún parámetro decimos que lo que ofrece un servicio ‘best effort’.
- El contrato que especifica los parámetros de QoS acordados entre el proveedor y el usuario (cliente) se denomina SLA (Service Level Agreement).

Implementación de QoS


- Para la implementación de QoS en una red, es necesario llevar a cabo 3 pasos básicos, que asignen adecuadamente las prioridades a los distintos tipos de tráfico.
- Identificación de los requisitos de tráfico:
 - ✓ Hay que determinar los requisitos de QoS necesarios para los distintos tipos de tráfico, como por ejemplo el tráfico de voz y el de aplicaciones de misión crítica; e identificar qué tráfico de baja prioridad puede marcarse para ser transmitido mediante protocolos sin garantía de entrega.
- Definición de clases de tráfico:
 - ✓ Una vez identificado el tráfico, puede clasificarse en clases apropiadas como de prioridad alta, media, normal y baja.
- Definición de las políticas de QoS:
 - ✓ El último paso consiste en la definición de políticas de QoS que se aplicarán a cada clase. Estas políticas incluyen la planificación de las colas de tráfico y determinación de reglas para controlar la congestión.

Perfil de tráfico y vigilancia


- *Perfil de tráfico o conformado de tráfico (traffic shaping)*: condiciones máximas de uso de la red que el usuario se compromete a cumplir con el proveedor del servicio.
- *Vigilancia de tráfico (traffic policing)*: labor de monitorización que el proveedor realiza para asegurarse que el usuario cumple su palabra.
- Si el usuario incumple el proveedor puede:
 - ✓ Descartar el tráfico no conforme
 - ✓ Marcarlo como de ‘segunda clase’ y pasarlo a la red, o
 - ✓ Pasarlo a la red sin mas (no es habitual)

Pozal agujereado (leaky bucket)

- El pozal agujereado se utiliza para suavizar las ráfagas (traffic shaping) y para asegurar que el tráfico introducido es el acordado (traffic policing).
- El usuario dispone de un caudal constante ρ en la red (el agujero) y un buffer de una capacidad C (el pozal) que absorberá las ráfagas que produzca.
- Si el buffer se llena el tráfico excedente se considera no conforme. Normalmente se descarta o se pasa como tráfico de ‘segunda’ clase.




(a)



(b)

Ejemplo de pozal agujereado con agua y con paquetes

Traffic Shaping y Traffic Policing



**Conformado de Tráfico:
Cumplir el contrato**

- Algoritmo del pozal agujereado
- Limitar pico y tamaño de ráfagas
- Limitar retardo y jitter

**Vigilancia de Tráfico: Vigilar
y obligar su cumplimiento**

¿El tráfico recibido cumple el contrato?

Si no:

- Puede marcar celdas de 2ª clase
- Puede descartar celdas de 2ª clase


Pozal con crédito (token bucket)

- El pozal agujereado no fomenta el ‘ahorro’. Un usuario que no ha transmitido nada recibe el mismo servicio que uno que siempre ha transmitido con el caudal ρ .
- El pozal con crédito soluciona esto. Funciona así:
 - ✓ Cuando el usuario no transmite el pozal suma créditos.
 - ✓ El máximo crédito acumulable es igual a la capacidad del pozal.
 - ✓ Los créditos permiten transmitir con un caudal mayor (M) hasta que se consumen (normalmente M es la velocidad de la interfaz).
 - ✓ Cuando no hay crédito funciona como un pozal agujereado.
- A menudo se combina un pozal con crédito seguido de un pozal agujereado de caudal mayor

Concepto de flujo

- Un flujo es una secuencia de datagramas que se produce como resultado de una acción del usuario y requiere la misma QoS.
- Un flujo es simplex (unidireccional).
- Un flujo es la entidad más pequeña a la que los routers pueden aplicar una determinada QoS.
- **Ejemplo:** una videoconferencia estaría formada por cuatro flujos, dos en cada sentido, uno para el audio y otro para el vídeo.
- Los flujos pueden agruparse en clases; todos los flujos dentro de una misma clase reciben la misma QoS.

Flujos en una videoconferencia




- Flujo vídeo A->B: 147.156.135.22:2056 -> 158.42.35.13:4065
- Flujo audio A->B: 147.156.135.22:3567 -> 158.42.35.13:2843
- ← Flujo vídeo B->A: 158.42.35.13:1734 -> 147.156.135.22:6846
- Flujo vídeo B->A: 158.42.35.13:2492 -> 147.156.135.22:5387

Agrupación de flujos o clases en video

Flujo 'rojo' (128 Kb/s):

147.156.21.20.2038→158.26.112.76.2127




Identificación de flujos

- En IPv4 se hace por:
 - ✓ Dirección IP de origen
 - ✓ Puerto de origen
 - ✓ Dirección IP de destino
 - ✓ Puerto de destino
 - ✓ Protocolo de transporte utilizado (TCP o UDP)
- Los algoritmos que asignan recursos de enrutadores entre los paquetes de un flujo y entre los flujos competidores se llaman **algoritmos de programación de paquetes** (o algoritmos de cola).
- Se pueden reservar potencialmente tres tipos distintos de recursos para diversos flujos:
 - ✓ Ancho de banda.
 - ✓ Espacio de búfer.
 - ✓ Ciclos de CPU.


Algoritmos de cola

- Primero en entrar, primero en salir (FIFO)
 - ✓ FIFO no tiene concepto de prioridad ni clases de tráfico, por lo que no toma decisiones sobre la prioridad de los paquetes.
 - ✓ FIFO, que es el método más rápido de espera, es eficaz para enlaces grandes que tienen poco retraso y congestión mínima.




Algoritmos de cola (Cont.)

- Mecanismo de cola de espera equitativa ponderada (WFQ)
 - ✓ Un método de programación automatizada que proporciona la asignación del ancho de banda justo a todo el tráfico de red.
 - ✓ Aplica la prioridad o los pesos para identificar el tráfico y clasificarlo en conversaciones o flujos.
 - ✓ La WFQ no se utiliza con los túneles y el cifrado porque estas funciones modifican la información de contenido de paquete requerida.



Algoritmos de cola (Cont.)


- CBWFQ (mecanismo de cola de espera equitativa ponderada basada en clases)
 - ✓ Extiende la funcionalidad de WFQ estándar para proveer admisión para las clases de tráfico definidas por el usuario.
 - ✓ Para cuantificar una clase, le asigna el ancho de banda, el peso, y el límite de paquete máximo.
 - ✓ También especifica el límite de cola para esa clase, que es la cantidad máxima de paquetes que se pueden acumular en la cola de esa clase.
 - ✓ Los paquetes que pertenecen a una clase están sujetos al ancho de banda y a los límites de cola que caracterizan a la clase.



Algoritmos de cola (Cont.)

- Mecanismo de cola de baja latencia (LLQ)


- ✓ La LLQ proporciona la cola de prioridad estricta para CBWFQ, lo que reduce las fluctuaciones en las conversaciones de voz.
- ✓ El ancho de banda asignado a los paquetes de una clase determina el orden en que se envían los paquetes.
- ✓ Sin la LLQ, se realiza el servicio de todos los paquetes en base suficiente al peso; ninguna clase de paquetes puede otorgar la prioridad estricta.
- ✓ La LLQ permite que los datos susceptibles a la demora, como la voz, se envíen primero.



Síntesis

- Control de Congestión $\neq$ Control de Flujo
- El control de la congestión y la calidad del servicio se centran principalmente en el tráfico de datos.
- En el control de la congestión, buscamos evitar la congestión del tráfico.
- En la calidad del servicio, buscamos crear un entorno adecuado para el tráfico.
- La congestión en una red puede ocurrir si la carga de la red (la cantidad de paquetes enviados a la red) es mayor que su capacidad (la cantidad de paquetes que una red puede gestionar).
- Dos soluciones podrían ser aplicadas: aumentar los recursos o reducir la carga.
- El control de la congestión se refiere a los mecanismos y técnicas para controlar la congestión y mantener la carga por debajo de su capacidad.
- En general, podemos dividir los mecanismos de control de la congestión en dos grandes categorías: control de la congestión de bucle abierto (prevención) y control de la congestión de bucle cerrado (eliminación).

Síntesis (cont.)



Síntesis (cont.)

- Algunas de las herramientas de QoS son:
 - Clasificación y marcación
 - Prevención para evitar la congestión
 - Modelado y regulación
- Los principales algoritmos para gestión de encolamiento son:
 - Primero entrado – Primero Salido (FIFO)
 - Mecanismo de cola de espera equitativa ponderada (WFQ)
 - Mecanismo de cola de espera equitativa ponderada basada en clases (CBWFQ)
 - Mecanismo de cola de baja latencia (LLQ)

FIN

gvillarreal@frc.utn.edu.ar